АНАЛИТИЧЕСКИЙ ОТЧЕТ ПО РЕЗУЛЬТАТАМ МОДЕЛИРОВАНИЯ

БИОХИМИЧЕСКОЙ АКТИВНОСТИ СОЕДИНЕНИЙ

Цель работы: Построение и сравнительный анализ моделей машинного обучения для предсказания параметров противовирусной активности (IC50, CC50, SI) на основе дескрипторов химических соединений, а также бинарной классификации по превышению медианных значений и порога безопасности.

1. Исследовательский анализ данных (EDA)

В ходе первичного анализа (ноутбук 01_EDA_analysis.ipynb) были сделаны следующие выводы:

- **Размерность:** 998 образцов, 213 признаков.
- **Пропуски:** Обнаружено 0.3% пропусков (удалены).
- **Распределение:** Целевые переменные (IC50, CC50, SI) имеют **сильную правостороннюю асимметрию** (длинный хвост из больших значений). Это потребовало логарифмического преобразования для регрессионных задач.
- **Выбросы:** В переменной SI обнаружены экстремальные значения (до 15620), что потребовало применения *clipping* (ограничения сверху на уровне 99-го перцентиля).
- **Корреляция:** Выявлены признаки с корреляцией > 0.95, которые были удалены перед обучением для борьбы с мультиколлинеарностью.

2. Результаты моделирования

Сравнивались 5 моделей: LinearRegression (с масштабированием), Random Forest, Gradient Boosting, CatBoost и XGBoost.

Подбор гиперпараметров не проводился в полном объёме ввиду высокой вычислительной сложности, поэтому в работе использовались значения гиперпараметров по умолчанию / предварительно подобранные вручную.

2.1. Задачи регрессии

Задача	Лучшая модель	R^2 (лучший)	R^2 (Linear Reg)	Вывод
IC50	CatBoost	**0.456**	0.081	Ансамблевые методы значительно лучше линейных. Связь нелинейная.
CC50	XGBoost	**0.329**	-0.226	Самая сложная цель для предсказания. Модели объясняют лишь ~33% дисперсии.
SI	GradientBoosting	**0.916**	-137.6	**Отличный** результат, так как SI = CC50 / IC50. Модель легко восстановила зависимость.

2.2. Задачи классификации (ROC-AUC)

Задача	Лучшая модель	ROC-AUC	Комментарий
IC50 > медианы	Random Forest	**0.790**	Хорошее качество разделения классов.
CC50 > медианы	Random Forest	**0.865**	**Отличный** результат. Классы хорошо разделимы.

SI > медианы	Random Forest	**0.682**	Удовлетворительно, классы путаются (вероятно из-за шума в SI).
SI > 8	Random Forest	**0.736**	Хорошо. Модель справляется с несбалансированным классом (35% положительных).

3. Сравнительный анализ моделей

- **Линейная регрессия:** Показала крайне низкие результаты (R^2 близок к 0 или отрицателен). **Вывод:** Зависимости в данных носят **нелинейный** характер.
- **Random Forest / Gradient Boosting / XGBoost / CatBoost:**
  - Показали стабильно хорошие результаты.
  - **CatBoost** был лучшим для IC50.
  - **XGBoost** был лучшим для CC50.
  - **Gradient Boosting** был лучшим для SI.
- **Общее наблюдение:** Random Forest оказался самой стабильной моделью для классификации, занимая 1-е места

4. Заключение и рекомендации

1. **Наиболее эффективные модели:**
   - Для **регрессии** (предсказание численных значений) рекомендуется использовать **CatBoost** или **XGBoost**.
   - Для **классификации** (распределение по категориям) рекомендуется использовать **Random Forest**.
2. **Качество предсказания:**
   - Прогноз SI получается **отлично** ($R^2 > 0.9$), что ожидаемо, так как он является производным от двух других переменных.
   - Прогноз IC50 и CC50 получается **удовлетворительно** (R^2 0.3-0.45). Это говорит о том, что используемых дескрипторов недостаточно для точного предсказания концентраций, либо в данных присутствует шум.
3. **Рекомендации по улучшению:**
   - Провести **отбор признаков** (Feature Selection) для удаления шумовых признаков.
   - Использовать **Stacking / Blending** (объединение моделей) для повышения точности.
   - Для задачи CC50 стоит попробовать нейросетевые подходы, так как градиентный бустинг объясняет лишь 33% дисперсии.